

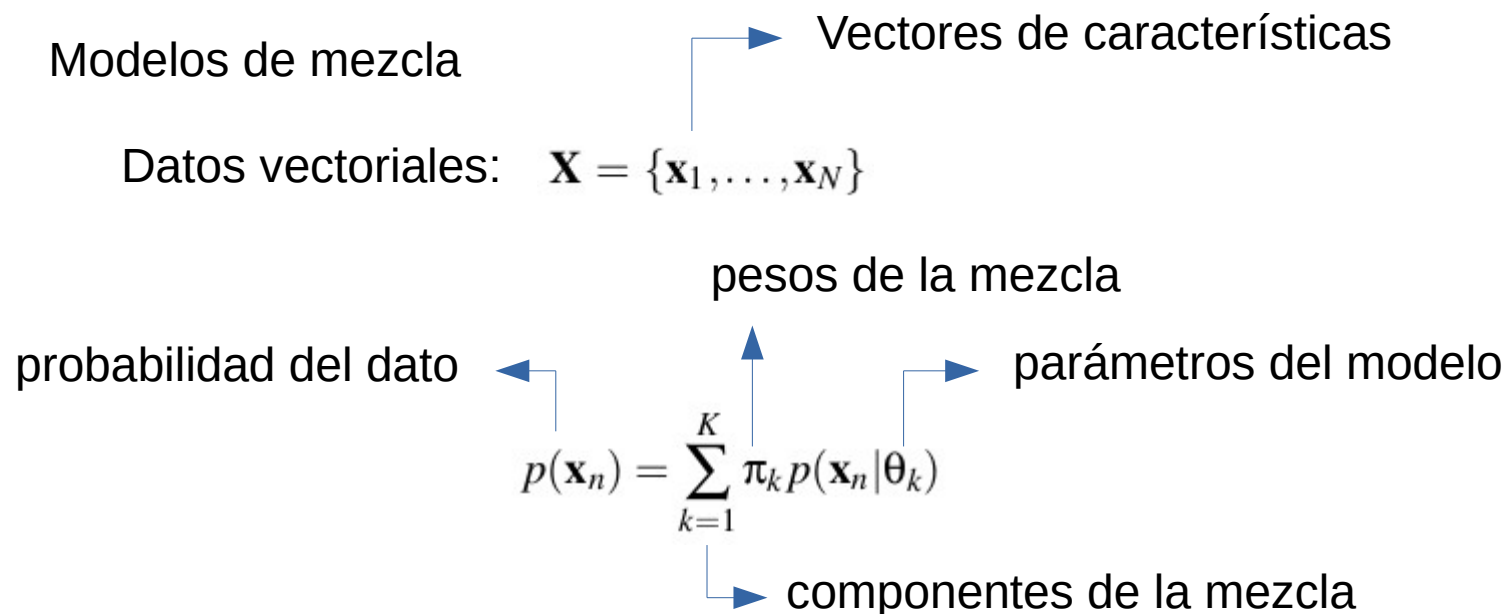


IIC 2433 Minería de Datos

<https://github.com/marcelomendoza/IIC2433>

- GMM -

Clustering probabilístico



Pesos de la mezcla:

$$0 \leq \pi_k \leq 1 \ (k = 1, \dots, K), \text{ y } \sum_{k=1}^K \pi_k = 1.$$

Clustering probabilístico

Modelos de mezcla

$$\Theta = \{\pi_1, \dots, \pi_K, \theta_1, \dots, \theta_K\}$$

Inferencia de parámetros del modelo: $\{\pi_k\}$ y $\{\theta_k\}$.

El número de componentes K se considera fijo (hiper-parámetro).

Asumimos que los datos son muestreados i.i.d., la probabilidad de generación del dataset es:

$$p(\mathbf{X}|\Theta) = \prod_{n=1}^N \sum_{k=1}^K \pi_k p(\mathbf{x}_n|\theta_k)$$

y en forma logarítmica:

$$\log p(\mathbf{X}|\Theta) = \sum_{n=1}^N \log \sum_{k=1}^K \pi_k p(\mathbf{x}_n|\theta_k).$$

Se usa el enfoque a máxima verosimilitud para inferencia:

$$\Theta_{ML} = \arg \max_{\Theta} \{\log p(\mathbf{X}|\Theta)\}$$



→ MLE: la mejor estimación es aquella que maximiza la probabilidad de generar las observaciones.

Clustering probabilístico

Modelos de mezcla



Bayes

$$\Theta_{ML} = \arg \max_{\Theta} \{\log p(\mathbf{X}|\Theta)\}$$

Verosimilitud (cuan probable es la evidencia condicionada al modelo)

Prior (nuestra creencia antes de observar la evidencia)

$$P(\Theta|X) = \frac{P(X|\Theta) \cdot P(\Theta)}{P(X)}$$

Posterior (cuan probable es el modelo condicionado a la evidencia)

Marginal (distribución de la evidencia, antes de pasar por el modelo)

Clustering probabilístico

Modelos de mezcla Gaussianas

Cada componente de la mezcla es una distribución Gaussiana.

$$\mathcal{N}(x|\mu, \sigma^2) = \frac{1}{(2\pi\sigma^2)^{1/2}} \exp\left\{-\frac{1}{2\sigma^2}(x - \mu)^2\right\}$$


media

varianza



Carl Gauss

Ej.:



Clustering probabilístico

Modelos de mezcla Gaussianas

Si \mathbf{x} es D dimensional:

$$\mathcal{N}(\mathbf{x}|\mu, \Sigma) = \frac{1}{(2\pi)^{D/2}} \frac{1}{|\Sigma|^{1/2}} \exp\left\{-\frac{1}{2}(\mathbf{x}-\mu)^T \Sigma^{-1}(\mathbf{x}-\mu)\right\}$$

Determinante de Σ

Matriz de covarianza $D \times D$


Vector de medias D -dimensional

$$\Sigma = \begin{pmatrix} \sigma_{11}^2 & \sigma_{12} & \dots & \sigma_{1m} \\ \sigma_{21} & \sigma_{22}^2 & \dots & \sigma_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{n1} & \sigma_{n2} & \dots & \sigma_{nm}^2 \end{pmatrix}$$



Carl Gauss

Ej.:



Clustering probabilístico



Carl Gauss

Modelos de mezcla Gaussianas

Cada componente está representada por los parámetros de una Gaussiana multivariada $p(\mathbf{x}_k|\theta_k) = \mathcal{N}(\mathbf{x}_n|\mu_k, \Sigma_k)$:

$$p(\mathbf{x}_n|\Theta) = p(\mathbf{x}_n|\pi, \mu, \Sigma) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}_n|\mu_k, \Sigma_k).$$

Dado \mathbf{X} , la función de verosimilitud queda dada por:

$$l(\Theta) = \log p(\mathbf{X}|\Theta) = \sum_{n=1}^N \log p(\mathbf{x}_n|\Theta) = \sum_{n=1}^N \log \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}_n|\mu_k, \Sigma_k).$$

Los parámetros del modelo son π_k , μ_k , y Σ_k .

Inferencia: basada en algoritmo Expectation - Maximization (EM).

Algorithm EM for Gaussian Mixtures

Given a set of data points and a Gaussian mixture model, the goal is to maximize the log-likelihood with respect to the parameters.

1: Initialize the means μ_k^0 , covariances Σ_k^0 , and mixing probabilities π_k^0 .

2: **E-step:** Compute

$$\gamma(z_{nk}) = \frac{\pi_k \mathcal{N}(\mathbf{x}_n | \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{x}_n | \mu_j, \Sigma_j)}.$$


3: **M-step:** Compute

$$\Sigma_k = \frac{\sum_{n=1}^N \gamma(z_{nk}) (\mathbf{x}_n - \mu_k) (\mathbf{x}_n - \mu_k)^T}{\sum_{n=1}^N \gamma(z_{nk})}, \quad \mu_k = \frac{\sum_{n=1}^N \gamma(z_{nk}) \mathbf{x}_n}{\sum_{n=1}^N \gamma(z_{nk})}, \quad \pi_k = \frac{\sum_{n=1}^N \gamma(z_{nk})}{N}$$

4: Compute the log-likelihood using $\sum_{n=1}^N \log \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}_n | \mu_k, \Sigma_k)$.


Inferencia: basada en algoritmo Expectation - Maximization (EM).

Algoritmo EM:



Initialize μ_k^0, Σ_k^0 , and π_k^0 .

E-step




$$\gamma(z_{nk}) = \frac{\pi_k \mathcal{N}(\mathbf{x}_n | \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{x}_n | \mu_j, \Sigma_j)}$$

$$\Sigma_k = \frac{\sum_{n=1}^N \gamma(z_{nk}) (\mathbf{x}_n - \mu_k) (\mathbf{x}_n - \mu_k)^T}{\sum_{n=1}^N \gamma(z_{nk})}$$


$$\mu_k = \frac{\sum_{n=1}^N \gamma(z_{nk}) \mathbf{x}_n}{\sum_{n=1}^N \gamma(z_{nk})}$$

$$\pi_k = \frac{\sum_{n=1}^N \gamma(z_{nk})}{N}$$

E-step




M-step




datos|distribución

distribución|datos



Iterar hasta converger

La idea del modelo generativo



- ANEXO -

MLE: debemos calcular las derivadas de $\log p(\mathbf{X}|\pi, \mu, \Sigma)$ w. r. t. π_k , μ_k , y Σ_k .

$$l(\Theta) = \log p(\mathbf{X}|\Theta) = \sum_{n=1}^N \log p(\mathbf{x}_n|\Theta) = \sum_{n=1}^N \log \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}_n|\mu_k, \Sigma_k).$$

$\frac{d}{dx}(\log(x)) = \frac{1}{x}$

$\frac{d}{dx}(\exp(f(x))) = e^{f(x)} f'(x)$

posterior

$$\frac{\partial l}{\partial \mu_k} = \frac{\sum_{n=1}^N \frac{\pi_k \mathcal{N}(\mathbf{x}_n|\mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{x}_n|\mu_j, \Sigma_j)} \Sigma_k^{-1} (\mathbf{x}_n - \mu_k)}{\sum_{n=1}^N \gamma(z_{nk}) \Sigma_k^{-1} (\mathbf{x}_n - \mu_k)} = 0$$

$$\frac{\partial \mathbf{L}}{\partial \mu} = -\frac{1}{2} \left(\frac{\partial (\mathbf{y} - \mu)' \Sigma^{-1} (\mathbf{y} - \mu)}{\partial \mu} \right)$$

$$= -\frac{1}{2} (-2 \Sigma^{-1} (\mathbf{y} - \mu))$$

$$= \Sigma^{-1} (\mathbf{y} - \mu)$$

Análogamente, obtenemos:

$$\Sigma_k = \frac{\sum_{n=1}^N \gamma(z_{nk}) (\mathbf{x}_n - \mu_k) (\mathbf{x}_n - \mu_k)^T}{\sum_{n=1}^N \gamma(z_{nk})}$$

$$\mu_k = \frac{\sum_{n=1}^N \gamma(z_{nk}) \mathbf{x}_n}{\sum_{n=1}^N \gamma(z_{nk})}$$

$$\gamma(z_{nk}) = \frac{\pi_k \mathcal{N}(\mathbf{x}_n|\mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{x}_n|\mu_j, \Sigma_j)}$$

MLE: debemos calcular las derivadas de $\log p(\mathbf{X}|\pi, \mu, \Sigma)$ w. r. t. π_k , μ_k , y Σ_k .

... falta un poco:

se agrega ya que los π_k deben ser positivos y sumar 1.

$$\log p(\mathbf{X}|\pi, \mu, \Sigma) + \lambda \left(\sum_{k=1}^K \pi_k - 1 \right).$$

$$\pi_k = \frac{\sum_{n=1}^N \gamma(z_{nk})}{N}$$