



IIC 2433 Minería de Datos

<https://github.com/marcelomendoza/IIC2433>

- CLASIFICACIÓN -

Clasificación

¿Cuáles de estos ejemplos son árboles?



Clasificación

input $\mathbf{x} \in \mathbb{R}^d = \mathcal{X}$.

output $y \in \{-1, +1\} = \mathcal{Y}$. (Clasificación binaria)

target function $f : \mathcal{X} \mapsto \mathcal{Y}$. $\leftarrow f$ desconocida

data set $\mathcal{D} = (\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)$. \leftarrow Escenario supervisado

Objetivo de aprendizaje:

Queremos **aprender** f usando \mathcal{D} .

Clasificación

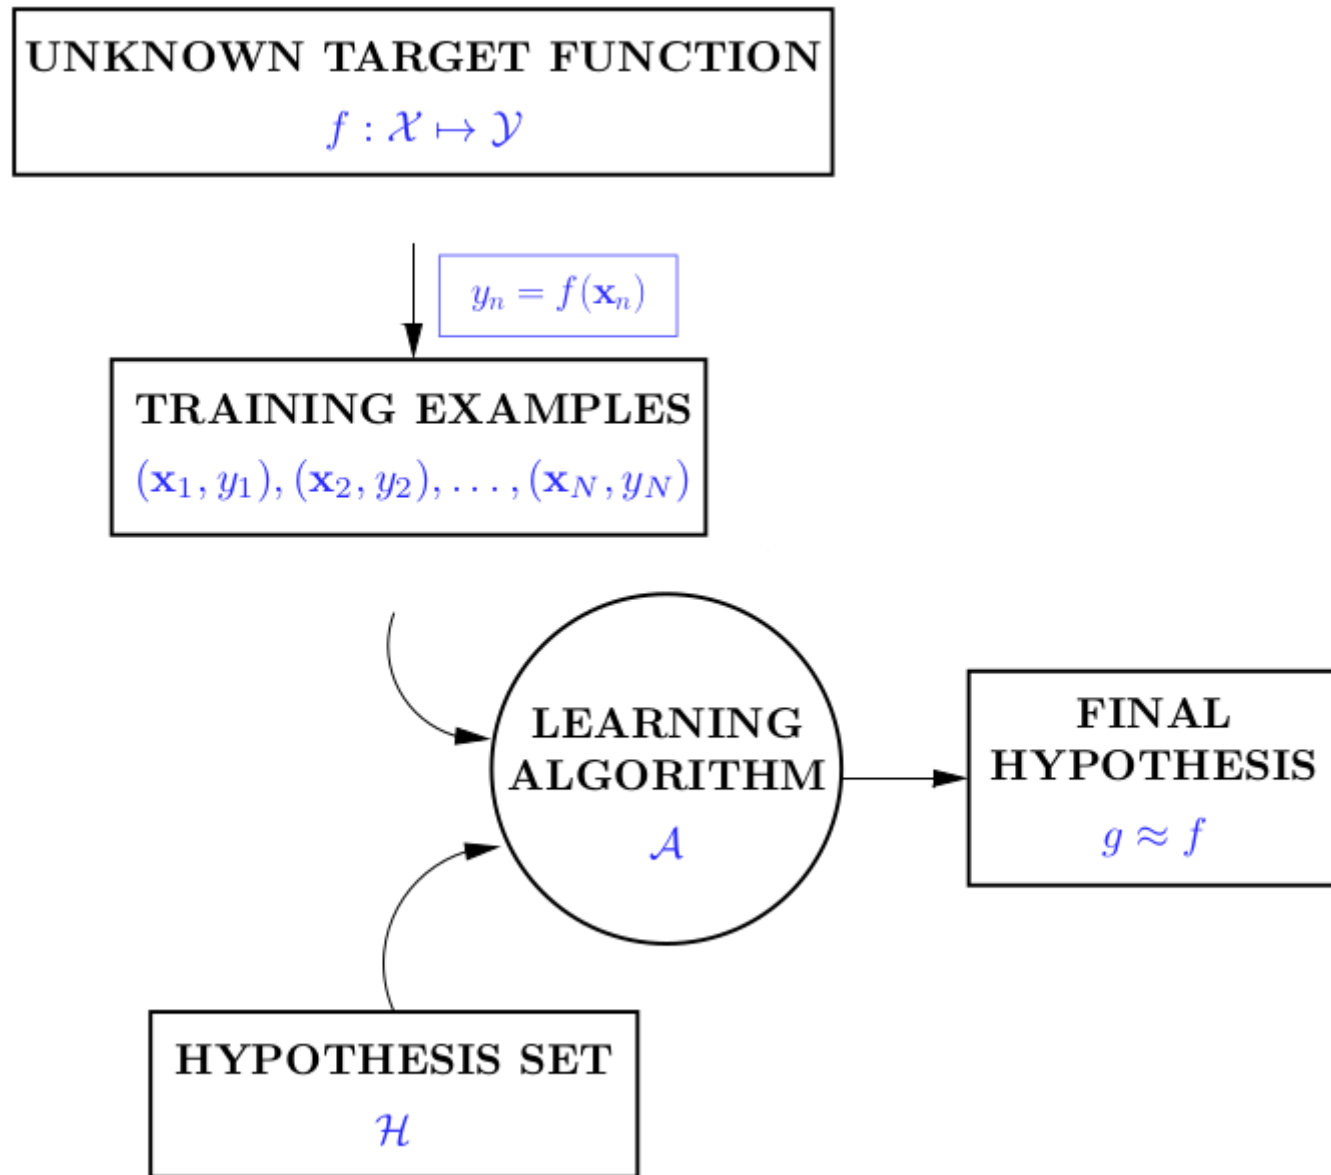
El algoritmo de aprendizaje

- Comenzamos con un conjunto de hipótesis candidatas \mathcal{H} que son factibles de representar f .

$$\mathcal{H} = \{h_1, h_2, \dots, \} \leftarrow \text{Conjunto de hipótesis}$$

- Un algoritmo A selecciona una hipótesis g desde \mathcal{H} . El algoritmo opera sobre datos etiquetados disponibles para seleccionar g (datos de entrenamiento).
- Para nuevos datos no etiquetados (i.e., y desconocido), usamos g para inferir y .

Clasificación



- PERCEPTRÓN LINEAL -

Un modelo simple (lineal)

age	32 years
gender	male
salary	40,000
debt	26,000
years in job	1 year
years at home	3 years
...	...

- Vector de características: $\mathbf{x} = [x_1, \dots, x_d]^T$.

- Aprenderemos distintos ‘pesos’ para las variables de entrada:

$$\text{“Credit Score”} = \sum_{i=1}^d w_i x_i.$$

¿Sujeto de crédito?

- Usaremos un **umbral** para decidir si aprobamos el crédito:

Aprobamos si: $\sum_{i=1}^d w_i x_i > \text{threshold}$, (score de crédito suficiente)

Rechazamos si: $\sum_{i=1}^d w_i x_i < \text{threshold}$. (score de crédito insuficiente)

Variable útil para mejorar el score: $w_i > 0$

Variable útil para disminuir el score: $w_i < 0$

Un modelo simple (lineal)

La hipótesis puede escribirse formalmente:

$$h(\mathbf{x}) = \text{sign} \left(\left(\sum_{i=1}^d w_i x_i \right) + w_0 \right)$$

Usamos el signo para tomar la
decisión

Bias (el umbral)

- El conjunto de hipótesis es:


$$\mathcal{H} = \{h(\mathbf{x}) = \text{sign}(\mathbf{w}^T \mathbf{x})\} \quad \leftarrow \text{Infinito si los pesos están en } \mathbb{R}$$

- Este modelo se llama **Perceptrón**:

$$\mathbf{w} = \begin{bmatrix} w_0 \\ w_1 \\ \vdots \\ w_d \end{bmatrix} \in \mathbb{R}^{d+1}, \quad \mathbf{x} = \begin{bmatrix} 1 \\ x_1 \\ \vdots \\ x_d \end{bmatrix} \in \{1\} \times \mathbb{R}^d.$$

El Perceptrón

- El Perceptrón usa los datos para encontrar una separación lineal según el atributo de clase y



- Como los datos están en un espacio de representación d -dimensional, el separador es un hiperplano.

El Perceptrón

Clasificación binaria: $\mathcal{Y} = \{+1, -1\}$

- 1: $\mathbf{w}(1) = \mathbf{0}$
- 2: **for** iteration $t = 1, 2, 3, \dots$
- 3: the weight vector is $\mathbf{w}(t)$. \leftarrow Random
- 4: From $(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)$ pick any misclassified example.
- 5: Call the misclassified example (\mathbf{x}_*, y_*) ,

$$\text{sign}(\mathbf{w}(t) \cdot \mathbf{x}_*) \neq y_*.$$


- 6: Update the weight:

$$\mathbf{w}(t+1) = \mathbf{w}(t) + y_* \mathbf{x}_*.$$

- 7: $t \leftarrow t + 1$



Update rule



Enfoque iterativo

El Perceptrón

Clasificación binaria: $\mathcal{Y} = \{+1, -1\}$

- Update rule (en ejemplos mal clasificados):

$$\mathbf{w}(t + 1) = \mathbf{w}(t) + y(t)\mathbf{x}(t).$$


El Perceptrón

Clasificación binaria: $\mathcal{Y} = \{+1, -1\}$

- Update rule (en ejemplos mal clasificados):

$$\mathbf{w}(t+1) = \mathbf{w}(t) + y(t)\mathbf{x}(t).$$

Ground truth \longrightarrow $y_* = +1$



Orienta \mathbf{w} hacia la dirección de \mathbf{x}


El Perceptrón

Clasificación binaria: $\mathcal{Y} = \{+1, -1\}$

- Update rule (en ejemplos mal clasificados):


$$\mathbf{w}(t+1) = \mathbf{w}(t) + y(t)\mathbf{x}(t).$$

Ground truth \longrightarrow $y_* = +1$



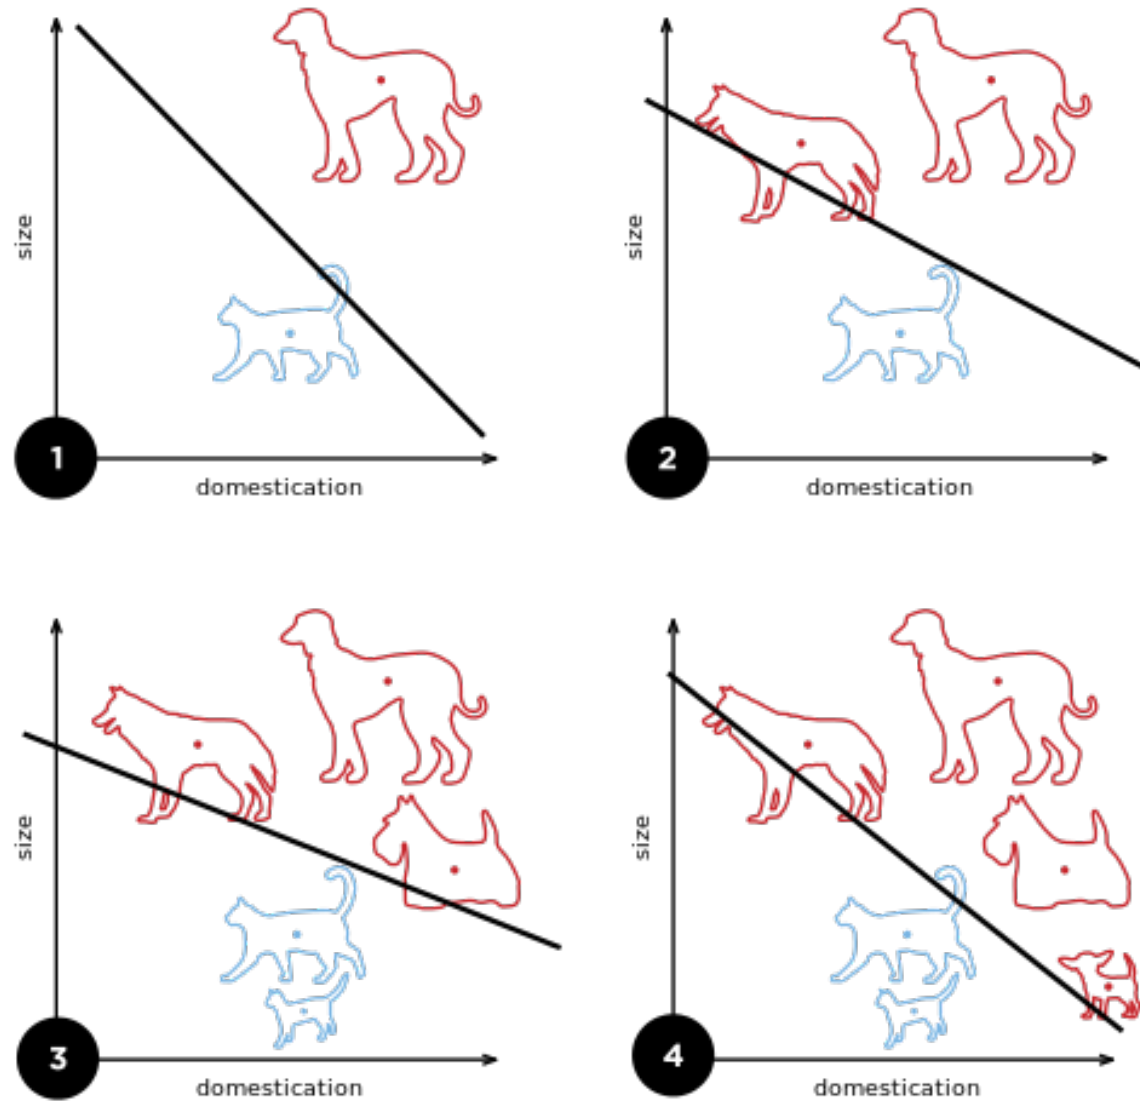
Orienta \mathbf{w} hacia la dirección de \mathbf{x}

$y_* = -1$ \longleftarrow Ground truth



Orienta \mathbf{w} en la dirección contraria de \mathbf{x}

El Perceptrón



- REGRESIÓN LOGÍSTICA -

Modelos lineales

entrada

↓


$$s = \mathbf{w}^T \mathbf{x}$$

↑

parámetros

Modelos lineales

$$y = \theta(s)$$



$$s = \mathbf{w}^T \mathbf{x}$$

↑
parámetros

entrada
↓

$$\{-1, +1\}$$

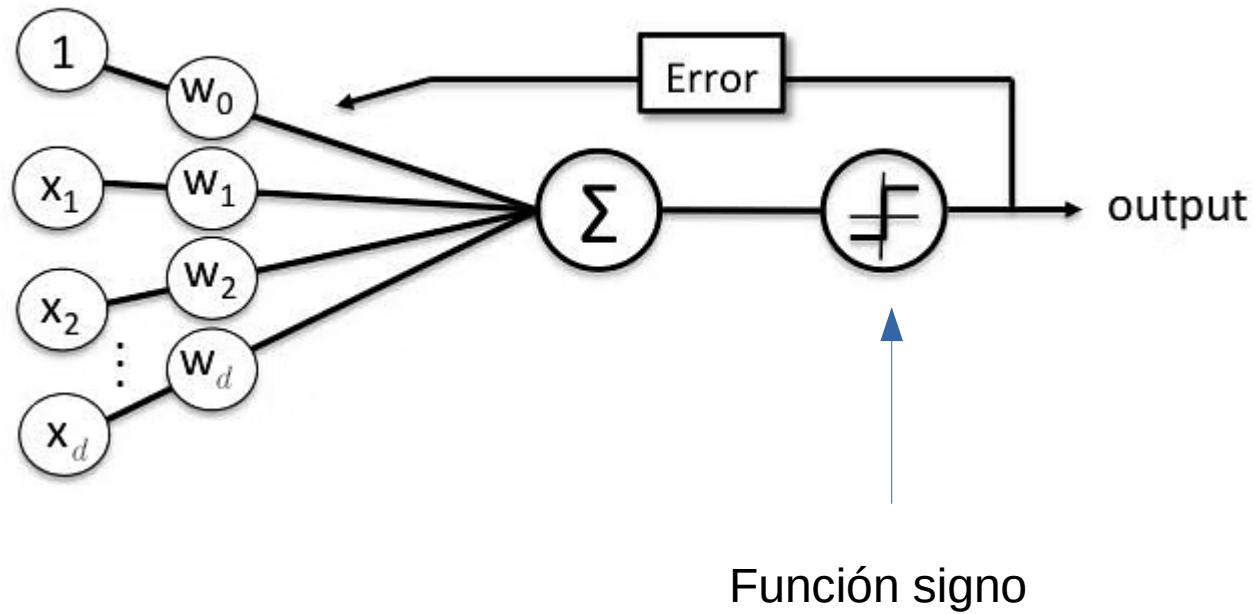
$$\mathbb{R}$$

$$[0, 1]$$

Perceptrón lineal

$$\mathcal{H}_{\text{lin}} = \{h(\mathbf{x}) = \text{sign}(\mathbf{w}^T \mathbf{x})\}$$

entrada
↓
 $s = \mathbf{w}^T \mathbf{x}$
↑
parámetros



Regresión logística

Objetivo:

$$f(\mathbf{x}) = \mathbb{P}[y = +1 \mid \mathbf{x}].$$

Regresión logística

Objetivo:

$$f(\mathbf{x}) = \mathbb{P}[y = +1 \mid \mathbf{x}].$$

Modelo:

$$h(\mathbf{x}) = \theta \left(\sum_{i=0}^d w_i x_i \right) = \theta(\mathbf{w}^T \mathbf{x})$$


Regresión logística

Objetivo:

$$f(\mathbf{x}) = \mathbb{P}[y = +1 \mid \mathbf{x}].$$

Modelo:

$$h(\mathbf{x}) = \theta \left(\sum_{i=0}^d w_i x_i \right) = \theta(\mathbf{w}^T \mathbf{x})$$



Regresión logística

Objetivo:


$$f(\mathbf{x}) = \mathbb{P}[y = +1 \mid \mathbf{x}].$$

Modelo:

$$h(\mathbf{x}) = \theta \left(\sum_{i=0}^d w_i x_i \right) = \theta(\mathbf{w}^T \mathbf{x})$$

Función logística:

$$y \in [0, 1]$$



$$\theta(s) = \frac{e^s}{1 + e^s} = \frac{1}{1 + e^{-s}}.$$

$$\theta(-s) = \frac{e^{-s}}{1 + e^{-s}} = \frac{1}{1 + e^s} = 1 - \theta(s).$$

Regresión logística


Notar que: $\mathcal{D} = (\mathbf{x}_1, y_1 = \pm 1), \dots, (\mathbf{x}_N, y_N = \pm 1)$

Un buen modelo logra lo siguiente:

$$\begin{cases} h(\mathbf{x}_n) \approx 1 & \text{si } y_n = +1; \\ h(\mathbf{x}_n) \approx 0 & \text{si } y_n = -1. \end{cases}$$

Clasificación multiclase

One-vs-all (one-vs-rest):




Class 1: \triangle \leftarrow

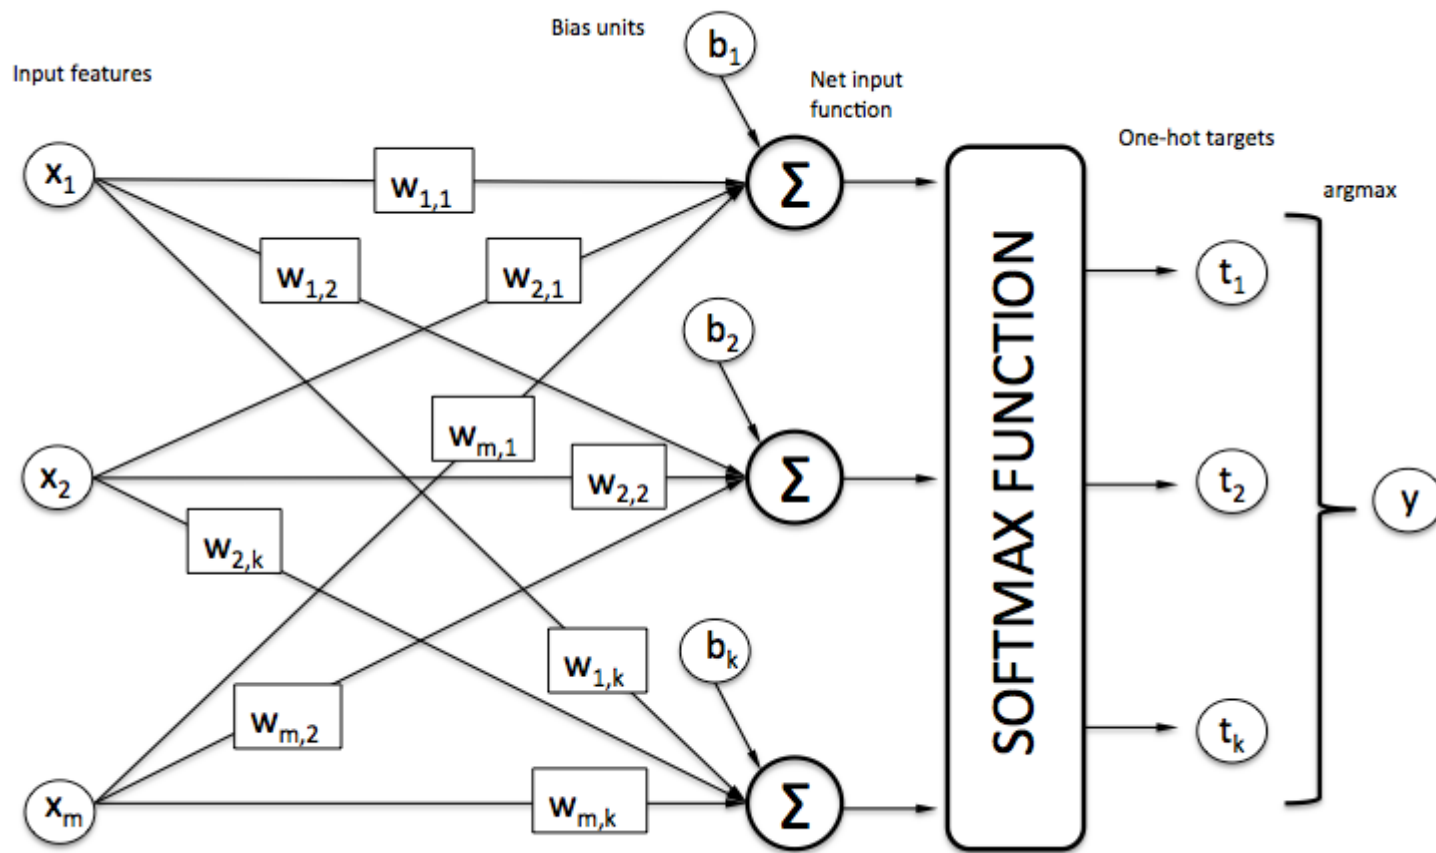
Class 2: \square \leftarrow

Class 3: \times \leftarrow

$$h_{\theta}^{(i)}(x) = P(y = i|x; \theta) \quad (i = 1, 2, 3)$$



Clasificación multiclase



$$P(y = j \mid z^{(i)}) = \phi_{softmax}(z^{(i)})$$

6
11
7



$$\frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}}$$



.01
.97
.02

- MÉTRICAS DE RENDIMIENTO -

Métricas

		+1	-1		
VALORES PREDICCIÓN	+1	Verdaderos positivos	Falsos Positivos	+1	
	-1	Falsos Negativos	Verdaderos Negativos	-1	
		VALORES REALES			

Métricas

verdaderos positivos (TP)	falsos positivos (FP)
falsos negativos (FN)	verdaderos negativos (TN)

$$\text{accuracy} = (TP + TN) / (TP + FP + FN + TN)$$

$$P = TP / (TP + FP)$$

$$R = TP / (TP + FN)$$

$$F = \frac{(\beta^2 + 1)PR}{\beta^2 P + R}$$

F-measure balanceada con $\beta = 1$